

-۱

$$P(\underbrace{y}_{\text{پار شدن}} \mid \underbrace{x_1}_{\text{معدل}} = \underbrace{x_2}_{\text{مطالعه}} = \underbrace{x_3}_{\text{خبر}})$$

$$= \frac{P(y) P(x_1, x_2, x_3 \mid y)}{P(x_1, x_2, x_3)}$$

$$P(x_1, x_2, x_3 \mid y) = P(x_1 \mid y) P(x_2 \mid y) P(x_3 \mid y)$$

$$y = \text{خبر} \Rightarrow \left. \begin{aligned} P(x_1 \mid y) &= \frac{0+1}{2+2} = \frac{1}{4} \\ P(x_2 \mid y) &= \frac{0+1}{2+2} = \frac{1}{4} \end{aligned} \right\}$$

$$P(x_3 \mid y) = 1$$

$$P(y) = \frac{1}{2}$$

$$\frac{1}{4} \times \frac{1}{4} \times \frac{1}{2} \times 1 = \frac{1}{32}$$

$$P(x_1 | y) = \frac{1}{2}$$

$$y = x \Rightarrow P(x_2 | y) = \frac{1}{2}$$

$$P(x_3 | y) = \frac{1}{2}$$

$$P(y) = \frac{1}{2}$$

$$\frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{16}$$

~~این احتمال بد~~ بودن بر حسب بیتر است

تاریخ: / / ۱۳۹۹

موضوع:

(الف)

$$P(A=0 | +) = \frac{2}{5} \quad P(A=0 | -) = \frac{3}{5}$$

$$P(A=1 | +) = \frac{3}{5} \quad P(A=1 | -) = \frac{2}{5}$$

$$P(B=0 | +) = \frac{4}{5} \quad P(B=0 | -) = \frac{3}{5}$$

$$P(B=1 | +) = \frac{1}{5} \quad P(B=1 | -) = \frac{2}{5}$$

$$P(C=0 | +) = \frac{1}{5} \quad P(C=0 | -) = 0$$

$$P(C=1 | +) = \frac{4}{5} \quad P(C=1 | -) = 1$$

$$P(y | A=0, B=1, C=0) = \frac{P(y) P(A=0, B=1, C=0 | y)}{P(A=0, B=1, C=0)}$$

$$y=+ \Rightarrow \frac{1}{2} \times \frac{2}{5} \times \frac{1}{5} \times \frac{1}{5} = \frac{1}{125}$$

$$y=- \Rightarrow \frac{1}{2} \times \frac{3}{5} \times \frac{2}{5} \times \frac{1}{5} = \frac{3}{125}$$

چون احتمال برپای (-) بیشتر است پس جواب (-) است


در این روش برای طبقه بندی ابتدا باید فاصله نقطه‌ی جدید را
 با تمام محاسبه کنیم پس نزدیک‌های نقطه‌ی جدید را به دست آورده و
 کلاس آن را به عنوان کلاس داده انتخاب می‌کنیم.

حال باید نمودار Voroni را رسم کنیم.

بین هر جفت نقطه خط کشیده و آن را به عنوان مرز در
 فضای $2D$ می‌کشیم.

نیمه‌های از مرز متصف‌ها که به یک نقطه نزدیک
 ترند را پاک می‌کنیم.

در نهایت باید از کلاس‌های پایان اجتماع بگیریم.



ب) بله، قابل استفاده است. به این صورت که ابتدا K همسایه نقطه جدید را پیدا می‌کنیم. سپس میانگین یا میانگین وزن دار مقادیر این نقاط را محاسبه کرده و به عنوان مقدار نقطه جدید در نظر می‌گیریم.

ج) خیر، پیشنهاد نمی‌شود چرا که در دیتاست‌های بزرگ هزینه محاسبه فاصله نقطه جدید تا تمام نقاط دیگر بسیار زیاد است و عملاً از نظر بار محاسباتی و زمانی بهینه نیست و عملکرد مطلوبی ندارد.

-۴

(الف)

در حالت $3-NN$ باید ۳ همسایه نزدیکتر به نقطه‌ی جدید را به دست آوریم و از فاصله‌ی اقلیدس استفاده می‌کنیم.

$(1,0) + (0,1) + (1,2) +$
 پس چون اکثریت با $(+)$ است کلاس داده ما $(+)$ است.

$7-NN$ ،
 $(1,0) + (0,1) + (1,2) +$
 $(0,2) - (2,2) - (1,-1) - (1,-1) -$
 طبق اکثریت کلاس داده ما $(-)$ می‌شود.


(ب)

در این حالت وزن در کلاس از فرمول $\sum \frac{1}{i^2}$ محاسبه می شود.

$\frac{1}{1} + \frac{1}{1} + \frac{1}{1} = 3 \rightarrow$ $3 - NN$
تأثیر (+) است

$y = + \Rightarrow 1 + 1 + 1 = 3$: $7 - NN$

$y = - \Rightarrow \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} + \frac{1}{4} + \frac{1}{4} = 1.5$



پس کلاس (+) وزن بیشتری دارد و انتخاب می شود.

CS Scanned with CamScanner

-۵

(الف)

روش اول One VS One است. در این روش ما بین هر دو کلاس از داده ها یک کلسیفایر باینری خواهیم داشت. در واقع به $m(m-1)/2$ SVM نیاز داریم. این روش به دلیل تعداد زیاد کلسیفایر به خصوص اگر تعداد کلاس ها زیاد باشد، می تواند از نظر محاسباتی بسیار پرهزینه باشد.

روش دوم One VS All است. در این روش ما به ازای هر کلاس یک SVM داریم. هر SVM برای تمایز یک کلاس از همه کلاس های دیگر آموزش داده می شود در نتیجه داده های دیگر ممکن است در یک کلاس نباشند. این روش عموماً سریعتر از OVO است

زیرا شامل کلسفایرهای کمتری است، اما ممکن است به اندازه کافی دقیق نباشد، به خصوص زمانی که کلاس‌ها به صورت خطی قابل تفکیک نیستند. تشخیص نوع گل از روی ویژگی‌های فیزیکی: فرض کنید می‌خواهیم یک مدل SVM چند کلاسه بسازیم که بتواند بین چندین نوع گل (مانند گل رز، بنفشه و نسترن) تمایز قائل شود و بر اساس ویژگی‌های فیزیکی مانند اندازه گلبرگ، رنگ گلبرگ، و طول ساقه داده‌های ما را طبقه‌بندی کند.

داده‌ها: مجموعه داده‌ای داریم که شامل چندین نمونه از هر نوع گل است. هر نمونه شامل ویژگی‌هایی مانند اندازه گلبرگ، رنگ گلبرگ، و طول ساقه است.

آموزش مدل:

- **روش OvO:** برای هر جفت گل (مثلاً رز و لاله، رز و نیلوفر آبی، و لاله و نیلوفر آبی) یک مدل SVM جداگانه آموزش می‌دهیم.
- **روش Ova:** برای هر نوع گل یک مدل SVM آموزش می‌دهیم که آن نوع گل را از سایر انواع تشخیص دهد.

پیش‌بینی: وقتی یک نمونه جدید (یک گل با ویژگی‌های ناشناخته) به مدل داده می‌شود، مدل بر اساس ویژگی‌های گل، نوع آن را تشخیص می‌دهد. در روش OvO، مدلی که بیشترین رأی را به یک نوع خاص بدهد، تعیین کننده نوع گل خواهد بود. در روش Ova، مدلی که بالاترین اعتماد یا فاصله از مرز تصمیم را داشته باشد، نوع گل را تعیین می‌کند.

(ب) حاشیه سخت به نوعی از حاشیه گفته می‌شود که اجازه نمی‌دهد هیچ نقطه داده‌ای در خود حاشیه باشد.

یک SVM با حاشیه سخت اصرار دارد که تمام نقاط داده باید خارج از حاشیه باشند. این بدان معنی است که هیچ گونه طبقه‌بندی اشتباه یا نقاطی را که در محدوده حاشیه قرار می‌گیرند تحمل نمی‌کند. این روش زمانی به خوبی کار می‌کند که داده‌ها به صورت خطی

قابل تفکیک باشند، به این معنی که این دو کلاس را می توان به طور کامل با یک خط مستقیم (یا ابر صفحه در ابعاد بالاتر) از هم جدا کرد. با این حال، ماهیت سخت گیرانه حاشیه سخت می تواند مدل را نسبت به موارد پرت حساس کند. اگر یک نقطه پرت وجود داشته باشد، می تواند به شدت بر موقعیت ابر صفحه تأثیر بگذارد و منجر به عملکرد تعمیم ضعیف در داده های جدید و نادیده شود.

-۶

(الف)

کارکرد موتور		p		کارکرد موتور
زیاد		۰.۱۵		
کم		۰.۱۵		

تخریب هوا		p		تخریب هوا
نام		۰.۵		
خواب		۰.۵		

کارکرد موتور		p (کارکرد موتور موتور)	
زیاد	خواب	۱/۳	
زیاد	بیدار	۱/۳	
کم	خواب	۱/۳	
کم	بیدار	۱/۳	

$P(\text{مردم هوا} | \text{قیمت})$

قیمت	مردم	هوا	P
زیار	فدب	نام	$\frac{2}{5}$
زیار	خوب	خواب	$\frac{1}{2}$
زیار	بد	نام	$\frac{1}{6}$
زیار	بد	خواب	0
کم	خوب	نام	$\frac{2}{5}$
کم	خوب	خواب	$\frac{2}{5}$
کم	بد	نام	$\frac{1}{5}$
کم	بد	خواب	$\frac{1}{5}$
			1

(ب)

$$P(\text{مردم هوا} = \text{بد}) = \sum_x P(\text{مردم} = \text{بد} | \text{مردم} = x) P(\text{مردم} = x)$$

$$\frac{1}{8} \left(\frac{1}{2} \times \frac{1}{2} + \frac{1}{2} \times \frac{1}{2} \right) = \frac{1}{4}$$

۷- روش Bagging چرا که در این روش ما تعدادی مدل را به صورت جداگانه آموزش می‌دهیم و این مدل‌ها بر روی یکدیگر تاثیری ندارند. (مانند درخت‌های تصمیم) در نهایت از روش Majority Voting برای پیش‌بینی کردن استفاده می‌کنیم.

عکس این روش Boosting است که ساخته شدن هر مدل بر شیوه ساخت مدل بعدی تاثیرگذار است.